PUC Rio

Pós-Graduação em Ciência de Dados e Analytics

Sprint: Engenharia de Dados

Aluna: Isabelle Fernandes Paixão da Silva

MVP - Engenharia de Dados

Objetivo:

Por meio de uma análise exploratória, esse projeto tem o objetivo de gerar insights e recomendar soluções para donos de imóveis que alugam suas residências através da plataforma Airbnb e interessados em alugar espaços por temporada. Segundo o próprio site, "O Airbnb nasceu em 2007, quando dois anfitriões receberam três hóspedes em sua casa em São Francisco. Hoje, a plataforma conta com 4 milhões de anfitriões que já receberam mais de 1,5 bilhão de hóspedes em quase todos os países do mundo. Todos os dias, os anfitriões oferecem acomodações e experiências únicas que possibilitam que os viajantes conheçam outras comunidades de uma forma mais autêntica."

Ou seja, a plataforma tem como objetivo facilitar que viajantes tenham possibilidade de se hospedar no destino escolhido para sua viagem, sem necessariamente recorrer a hotéis.

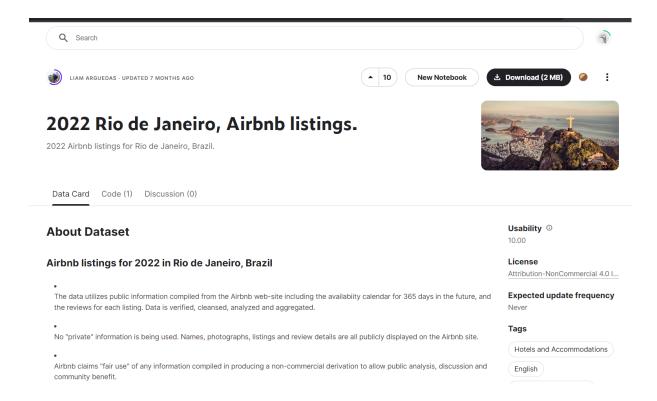
Vou responder, levando em consideração apenas a cidade do Rio de Janeiro no ano de 2022, as seguintes perguntas:

- 1. Qual é a média do mínimo de noites para aluguel?
- 2. Qual a categoria de imóvel está disponível em maior número?
- 3. Qual a média dos preços de aluguel?
- 4. Qual a localidade mais cara no Rio de Janeiro?
- 5. Quais são os bairros mais baratos?
- 6. Houve procura de imóveis por influência de eventos na cidade?

Detalhamento:

1. Busca pelos dados

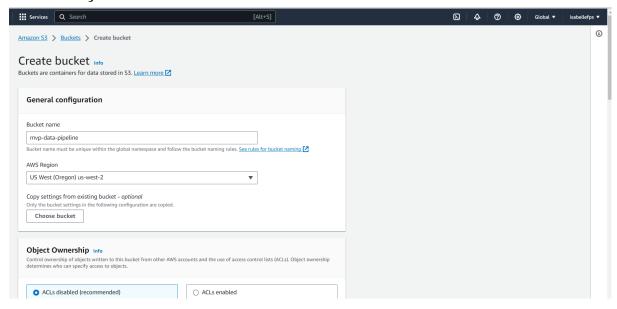
A <u>base de dados escolhida</u> refere-se a acomodações localizadas na cidade do Rio de Janeiro em 2022. Sua fonte foi o Kaggle:

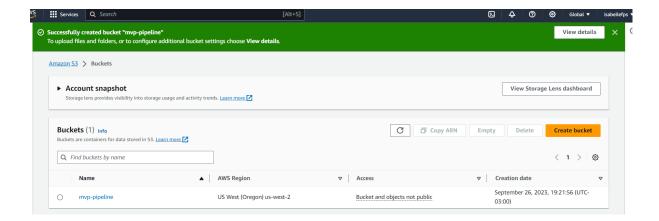


2. Coleta

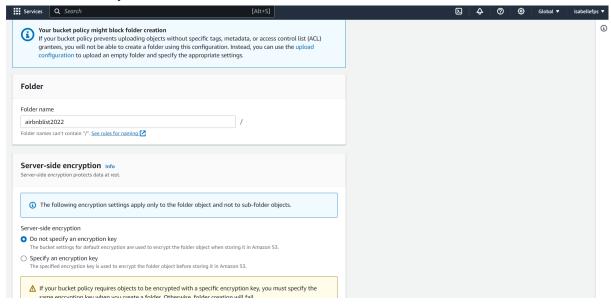
A nuvem escolhida por mim foi AWS. Após a escolha dos dados, foi feita a coleta. Os dados baixados na máquina local e inseridos manualmente em um bucket S3:

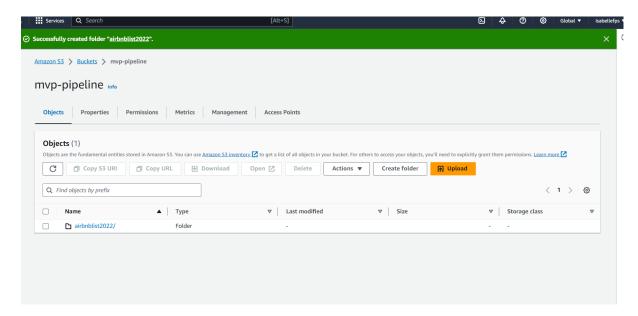
a. Criação S3:



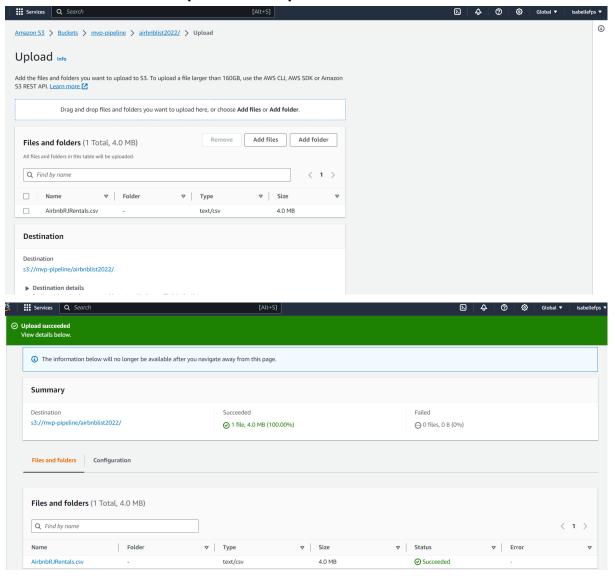


b. Criando pasta dentro do bucket:





c. Adicionando o arquivo .csv na pasta:

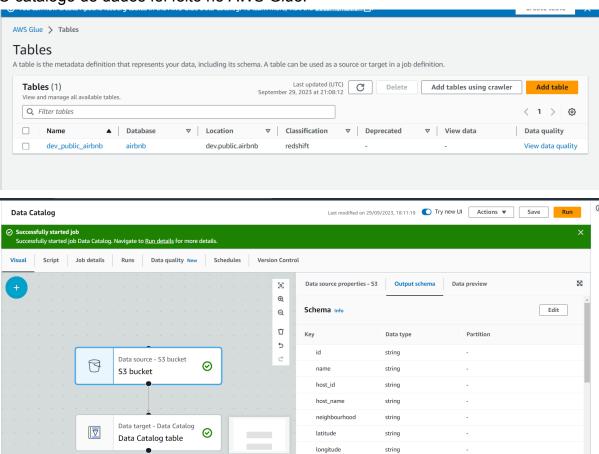


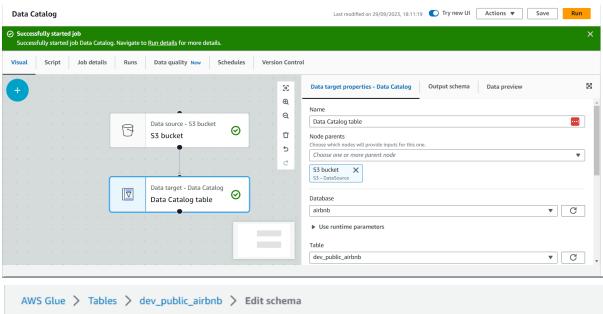
3. Modelagem

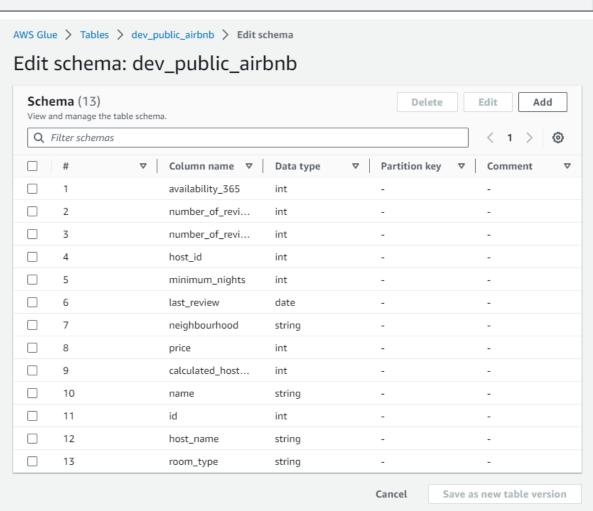
A modelagem dos dados foi feita em Flat Table:

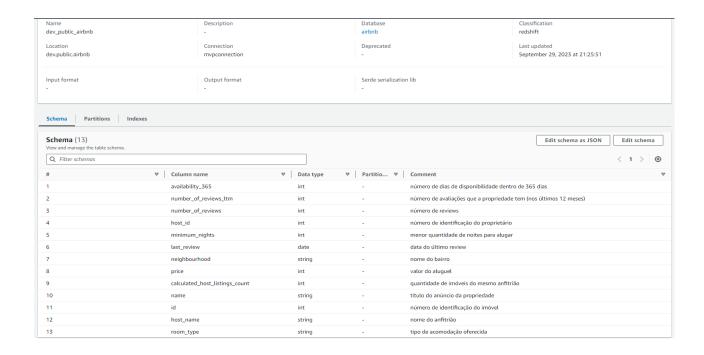
airbnb
id
name
host_id
host_name
neighbourhood
room_type
price

O catálogo de dados foi feito no AWS Glue:



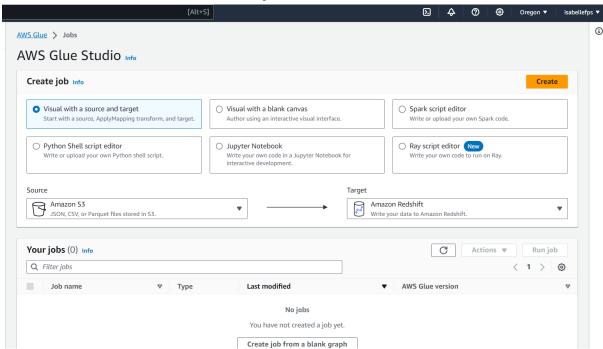






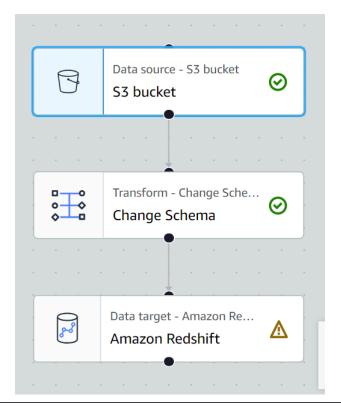
4. Carga:

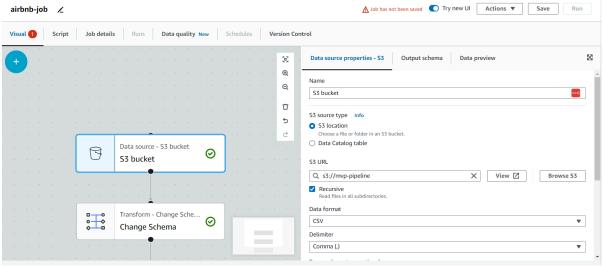
O ETL foi realizado utilizando o serviço AWS Glue.



Foram criadas as seguintes etapas:

a. Na etapa 1, "Data source - S3 bucket", foram realizadas as configurações para extrair (Extract) os dados da fonte, no caso a pasta "AirbnbRJRentals" do bucket "mvp-pipeline":





b. Na etapa 2, "Transform - Change Schema", realizamos a etapa de transformação (Transform) dos dados.

Foi feito o drop dos campos:

- latitude
- longitude
- reviews_per_month

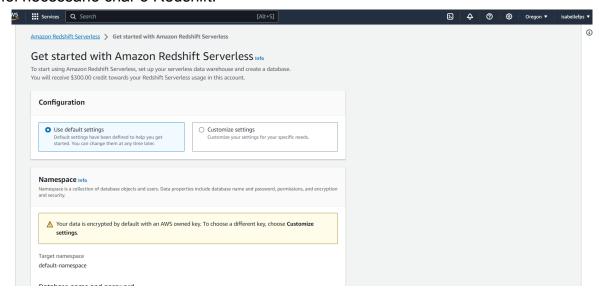
Os campos abaixo foram transformados em int:

- id
- host_id
- price

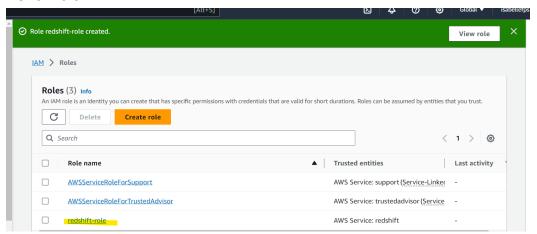
- minimum nights
- number of reviews
- calculated_host_listings_count
- availability 365
- number_of_reviews_ltm

O campo last_review foi transformado em date.

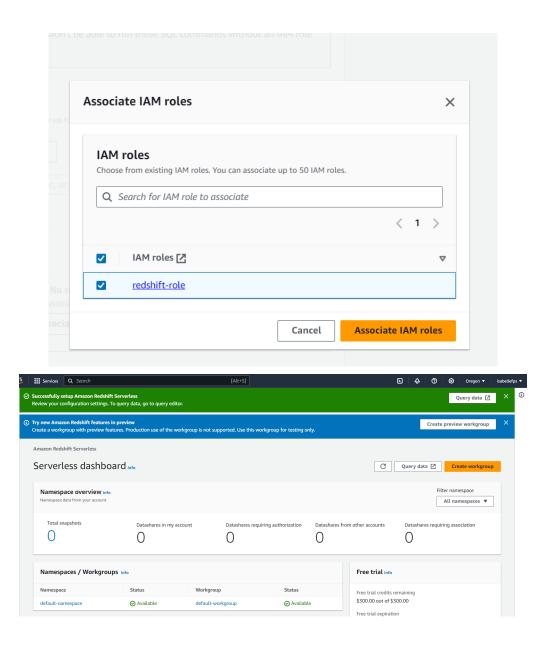
Antes de prosseguir com a etapa de carregamento, "Data target - Amazon Redshift", foi necessário criar o Redshift:



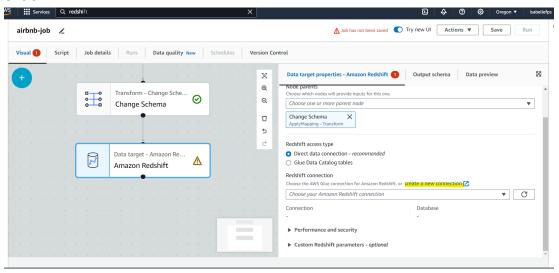
1. Criar role:

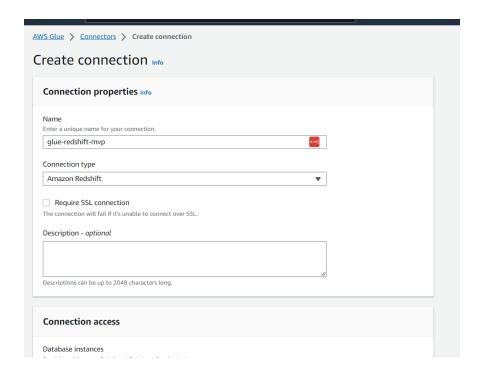


2. Após associar o role feito acima, o Redshift foi criado:

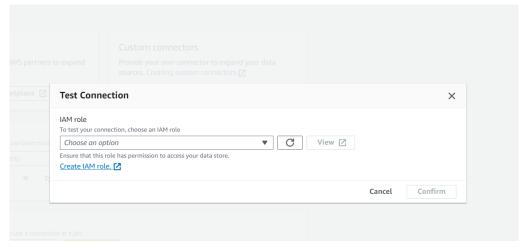


c. De volta a etapa 3, "Data target - Amazon Redshift", foi necessário criar a conexão:

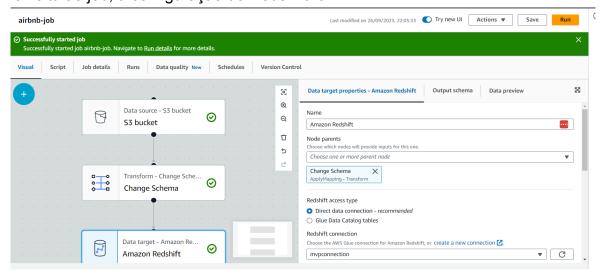




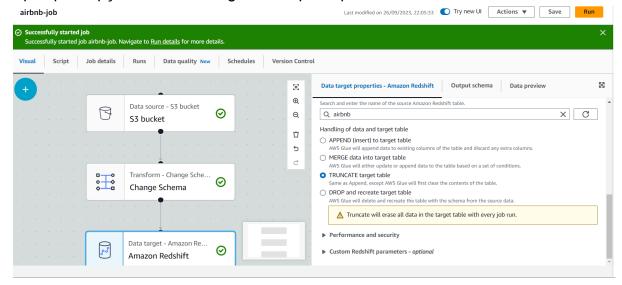
Ao testar a conexão, foi necessário criar um IAM role para o Glue:



De volta ao job, a configuração do Redshift foi:



Optei pela opção "Truncate target table" para que a tabela fosse criada.



Run Job:

Os primeiros falharam, pois, na etapa 2 "Transform - Change Schema", eu havia alterado o nome da coluna *number_of_reviews_ltm* para *number_of_reviews*, sem perceber que era exatamente o nome de uma mesma coluna da tabela. Ao notar o erro, voltei na etapa 2 e retornei a coluna para o nome original:

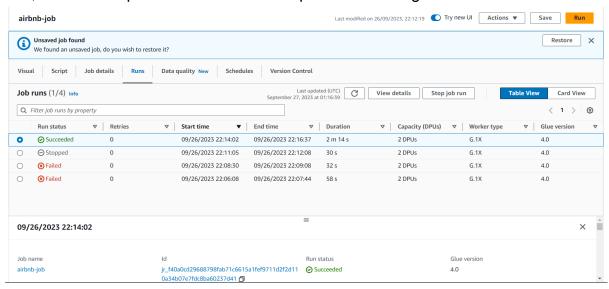
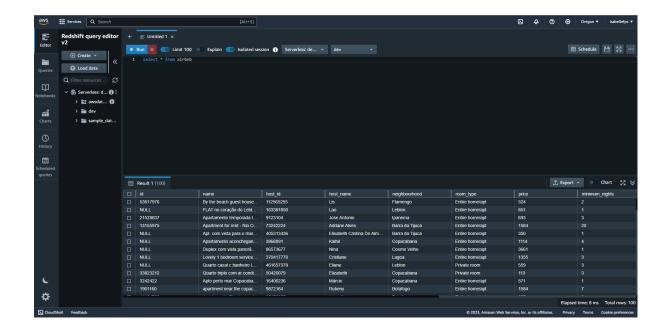


Tabela criada corretamente:



5. Análise:

a. Qualidade dos dados:

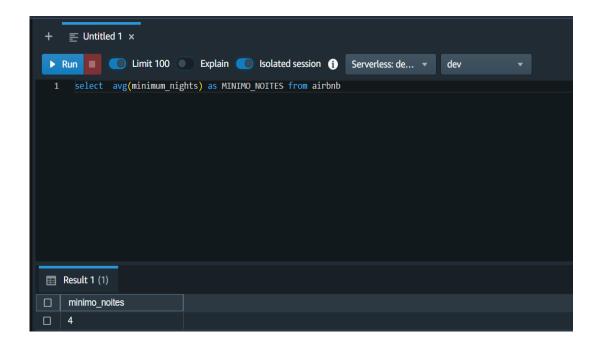
Encontrei alguns nulos principalmente nas colunas *id* e *last_review*. Os nulos nesses casos não foram removidos, pois, não atrapalham as respostas das perguntas que eu quero solucionar. A coluna *reviews_per_month* foi removida, porque além de muitos nulos, não seria útil para responder as perguntas que coloquei no objetivo. As colunas *latitude* e *longitude* também foram removidas por esse motivo.

b. Solução do problema:

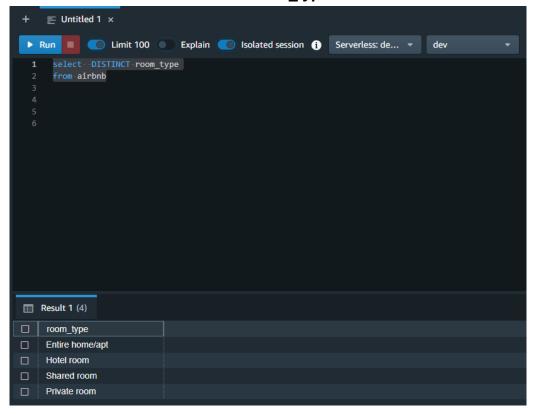
1. Qual é a média do mínimo de noites para aluguel?

Para se hospedar no Rio de Janeiro, a média de noites é de no mínimo 4 noites . Isso indica que os anfitriões costumam disponibilizar os imóveis, por pelo menos 3 ou 4 noites em sua maioria, fazendo com que os hóspedes passem ao menos o fim de semana hospedados:

select avg(minimum nights) as MINIMO NOITES from airbnb



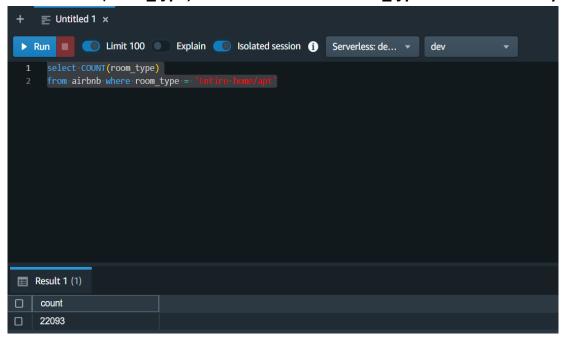
2. Qual a categoria de imóvel está disponível em maior número? select DISTINCT room_typefrom airbnb



Eu decidi transformar essa pergunta em: Entre as categorias "Entire home/apt" e "Private room", qual está disponível em maior número?

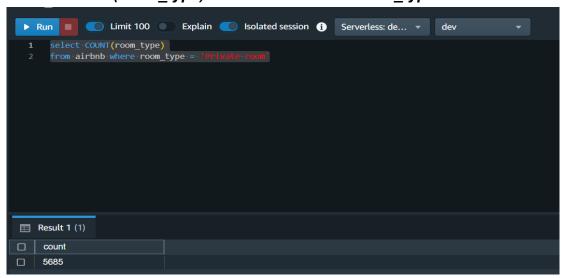
A opção "Entire home/apt" trouxe 22093 como resultado:

select COUNT(room type) from airbnb where room type = 'Entire home/apt'



A opção "Private room" trouxe 5685 como resultado:

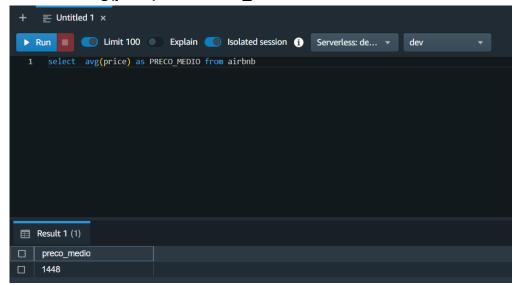
select COUNT(room_type) from airbnb where room_type = 'Private room'



3. Qual a média dos preços de aluguel?

A média de preço para se hospedar por noite no Rio é de R\$1.448:

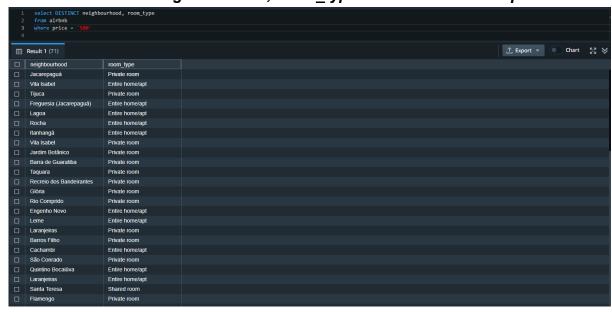
select avg(price) as PRECO MEDIO from airbnb



- 4. Para as perguntas 4 e 5, "Qual a localidade mais cara no Rio de Janeiro?" e "Quais são os bairros mais baratos?" decidi transformá-las em perguntas diferentes:
- a. Quais são as localidades com valor igual a R\$500 e seu tipo de acomodação?

Os resultados são principalmente bairros da Zona Norte e Centro do Rio de Janeiro, sendo quarto privado a maioria das acomodações:

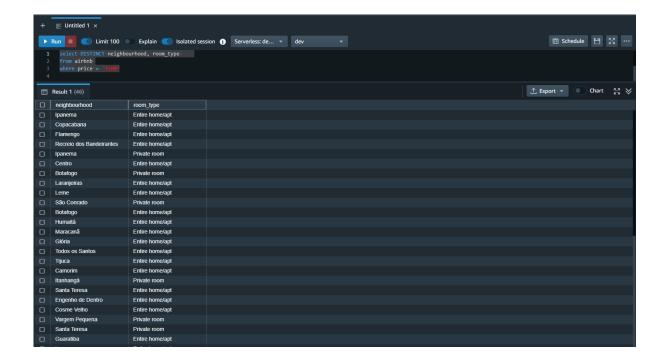
select DISTINCT neighbourhood, room_type from airbnb where price = '500'



b. Quais são as localidades com valor igual a R\$1200 e seu tipo de acomodação?

Neste caso, os resultados são principalmente bairros da Zona Sul do Rio de Janeiro, sendo o espaço inteiro a maioria das acomodações.

select DISTINCT neighbourhood, room_type from airbnb where price = '1200'

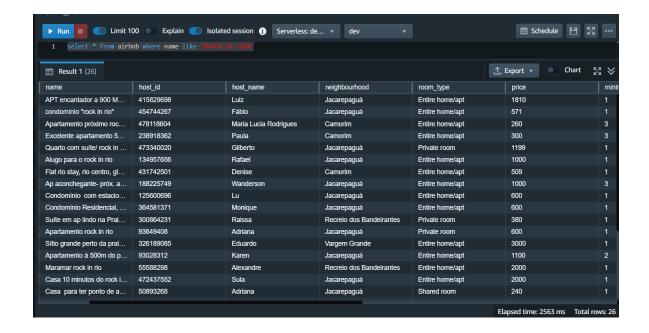


5. Houve procura de imóveis por influência de eventos na cidade?

O Rio de Janeiro é uma cidade turística com alta procura de hospedagem em qualquer época do ano, mas para interessados em disponibilizar o imóvel para locação, pode ser interessante saber que alguns eventos movimentam a procura em bairros específicos, como é o caso do Rock in Rio.

Para os dados do ano passado, o evento em evidência não gerou tantas oportunidades em destaque, tendo apenas 26 imóveis com "Rock in Rio" no título. A maior parte localizada no bairro de Jacarepaguá e com a possibilidade de alugar o ambiente inteiro.

select * from airbnb where name like '%rock in rio%'



Autoavaliação:

Subir o pipeline na nuvem foi a parte menos difícil. Tive alguns erros ao longo do desenvolvimento, mas foram rapidamente resolvidos entendendo o erro através dos logs e tirando dúvidas nas aulas.

Escolher a base de dados e definir o objetivo também foi simples, mas senti dificuldades para responder as perguntas que criei usando o SQL. Tentei algumas consultas que não retornaram o que eu gostaria, então mudei as perguntas 4 e 5. Decidi substituir por perguntas que fazem algum sentido nesse contexto, levando em consideração a realidade de aluguéis no Rio de Janeiro.

A minha conclusão é que preciso desenvolver e aprofundar mais meu conhecimento em banco de dados, principalmente SQL. Apesar de ser o fim dessa sprint, vou continuar estudando os temas abordados e vou retornar neste trabalho e responder as perguntas do objetivo inicial.